Actividad 4 - Práctica: Regresión Logística y modelos sub y sobre entrenados

Denisse María Ramírez Colmenero
A01561497

Materia: Inteligencia artificial y aprendizaje automático
Fecha: 1 de octubre de 2022

1.- Con base a la exactitud y desviación estándar de cada modelo mostrados en los resultados anteriores, ¿qué puedes decir del modelo generado? ¿Ayudan en este caso el uso de las técnicas de regularización para obtener un mejor modelo? ¿Podríamos considerar las diferencias mostradas entre ellos suficientes como para hablar de que uno de ellos es mejor que los otros?

Aún sin realizar algún cambio en los modelos y observando los resultados obtenidos de exactitud del modelo y desviación estándar de los diferentes métodos de aprendizaje supervisado podemos darnos cuenta que el modelo de regresión logística resulta el más exacto, es decir, que tiene el mayor desempeño promedio, mientras que el MLP (modelo de red neuronal artificial) tiene una menor dispersión de sus datos.

Por otro lado, cuando aplicamos este comparativo con la regresión logística y las técnicas de regularización obtenemos que el modelo RIDGE tiene un mayor promedio y el modelo LASSO una desviación estándar menor.

```
>> LR 0.868 (0.050)
>> LASSO 0.867 (0.046)
>> RIDGE 0.869 (0.048)
>> EN 0.863 (0.048)
```

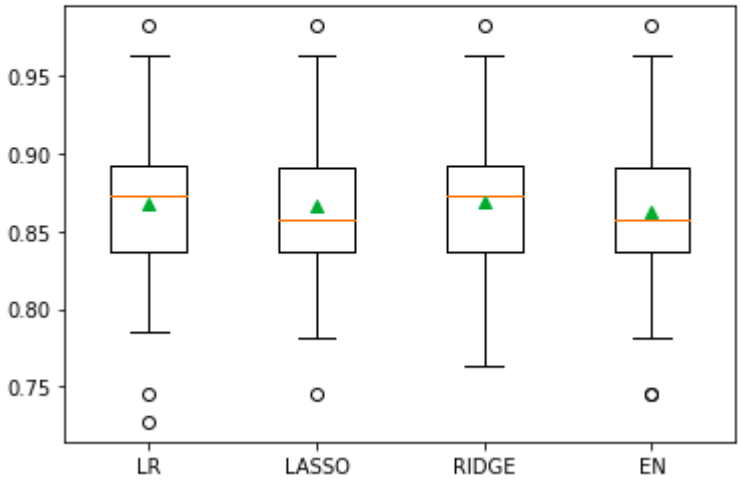

Figura 1. Resultados de exactitud y variación estándar y diagrama de caja y bigotes de las técnicas de regularización.

A simple vista podríamos decir que aquel modelo que obtenga un desempeño promedio mayor sería el mejor modelo, pero como vemos en este caso y posiblemente también en muchos otros, el promedio es muy similar entre todos los modelos pues son diferencias no mayores a 1% en la exactitud al menos entre el primero y el segundo mejor modelo, por lo que no quizá no sería muy prudente guiarnos solo por ese resultado y tendríamos que tener en cuenta otros parámetros, por ejemplo, la sencillez del modelo.
Por ejemplo en este caso, el modelo RIDGE tiene un mayor promedio, sin embargo, sabemos que este modelo requiere más instrucciones y lo hace un modelo más complejo que el LR, además que solo tiene un 0.001 de diferencia en su promedio.

Otra manera de analizar los diferentes modelos es observando su diagrama de caja y bigotes. Como podemos ver, todas los diagramas se parecen mucho entre sí, la media está casi en el mismo lugar y las longitudes de los bigotes son también muy iguales. Considero que lo que podríamos rescatar de esto sería la existencia de los *outliers*. El modelo RL tiene 3 outliers, LASSO y EN tienen dos, mientras que el modelo RIDGE solo uno, además se puede observar que la media (triangulo verde) y la mediana (línea naranja) están más juntas.

Considero que lo mejor sería hacer un análisis y comparar los modelos según la aplicación que se le quiera dar. A lo mejor si va a ser utilizado en una aplicación donde haya mucho en juego y se requiera el mejor desempeño posible, el resultado de la exactitud compense la complejidad del modelo, y por otro lado, si es para una aplicación un poco más práctica, lo ideal sería irnos por el modelo más sencillo. Lo mismo pasa con los outliers. Como ya aprendimos en la actividad anterior, los outliers se deben a errores de captura, de medición, por lo que declarar si estos toman un papel relevante o no y decidir qué hacer con ellos, si simplemente borrarlos o dejar que sean parte de la transformación, es decisión del analista y de la empresa, basándose obviamente en el tipo de problema que buscan resolver.

Realiza ajustes a los argumentos de algunos de los modelos y observa si puedes obtener un mejor resultado, al menos en cuanto a su promedio general.

2.- ¿Qué podrías concluir al respecto?

Los argumentos a los que realice un cambio fueron alfa y l1_ratio. Alfa es un hiperparámetro que representa la fuerza de la regularización. Si el valor de alfa es muy grande, la regularización va a ser mayor y por lo tanto, evita que el modelo sea sobreajustado (underfitting) y viceversa (overfitting).
Por otro lado, l1_ratio, el cual lo utilizamos en la técnica de Elastic Net, nos habla de la relación entre LASSO (L1) y RIDGE (L2) y puede tener un valor en 0 y 1. Si el valor se acerca a 1, L1 es más dominante y si es más cercano a 0, L2 será más dominante.

Analizando únicamente los resultado de promedio y desviación estándar podemos concluir que aun cuando el valor de alfa (***α***) y l1_ratio en el caso del modelo Elastic Net, los

resultados siguen siendo idénticos en ambos casos para todos los modelos de regularización y LR.

El diferentes valores para alfa (***α***) en un rango de 0.01 a 1000, mientras que para l1_ratio escogí valores de 0.25, 0.5 y 0.8. Para cualquier combinación de estos los resultados fueron los mismos que se observan en la figura 1 anteriormente.

3.- ¿Se obtuvo un buen ajuste en alguno de los modelos?

Si bien los valores de promedio y desviación estándar no cambian en los ajustes, una cosa en la que sí podemos ver cambio es en la gráfica y los coeficientes *w* (pesos). La siguiente tabla muestra los resultados de los coeficientes *w* pesos respecto a los valores de alfa (***α***) y l1_ratio que se aplicaron.

Alfa (α)	l1_ratio	LR	LASSO (L1)	RIDGE (L2)	ELASTIC NET
1000	0.5	[-40.14979 -179.70350 58.72754]	[-0 -0. -0]	[-1.5621 -2.6188 1.9319]	[-32.10655 -79.34645 28.06434]
40	0.5	[-40.14979 -179.70350 58.72754]	[-0 -72.2247 22.4585]	[-23.8432 -50.90446 18.75338]	[-32.10655 -79.34645 28.06434]
30	0.5	[-40.14979 -179.70350 58.72754]	[-0 -102.25253 31.42721]	[-27.51573 -61.84734 22.38804]	[-32.10655 -79.34645 28.06434]
30	0.8	[-40.14979 -179.70350 58.72754]	[-0 -102.25253 31.42721]	[-27.51573 -61.84734 22.38804]	[-38.3805 -117.8284 40.1517]
30	0.25	[-40.14979 -179.70350 58.72754]	[-0 -102.25253 31.42721]	[-27.51573 -61.84734 22.38804]	[-27.6496 -62.6227 22.63149]
5	0.5	[-40.14979 -179.70350 58.72754]	[-33.2662 -166.8287 54.1677]	[-40.5583 -135.4157 45.6077]	[-32.10655 -79.34645 28.06434]
1	0.5	[-40.14979 -179.70350 58.72754]	[-38.7818 -177.0978 57.8073]	[-40.7475 -168.5455 55.4734]	[-32.10655 -79.34645 28.06434]
0.01	0.5	[-40.14979 -179.70350 58.72754]	[-40.1362 -179.6769 58.7182]	[-40.157 -179.584 58.6929]	[-32.10655 -79.34645 28.06434]

Tabla 1. Resultados de los pesos de las técnicas de regularización según los valores de alfa y l1 ratio.

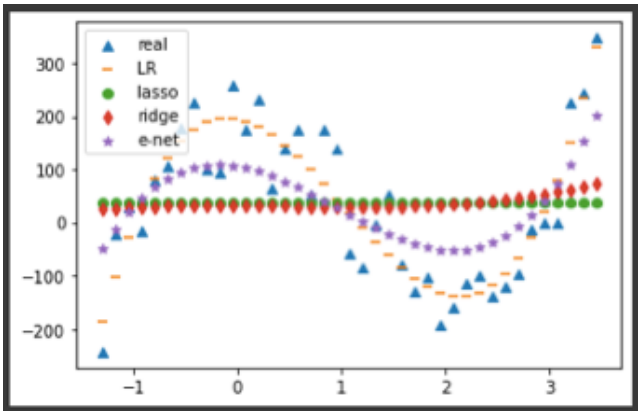

Figura 2. Técnicas de regularización, alfa = 1000.

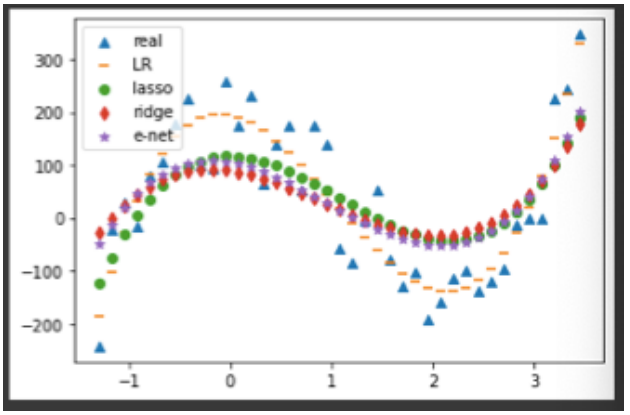

Figura 3. Técnicas de regularización, alfa = 30.

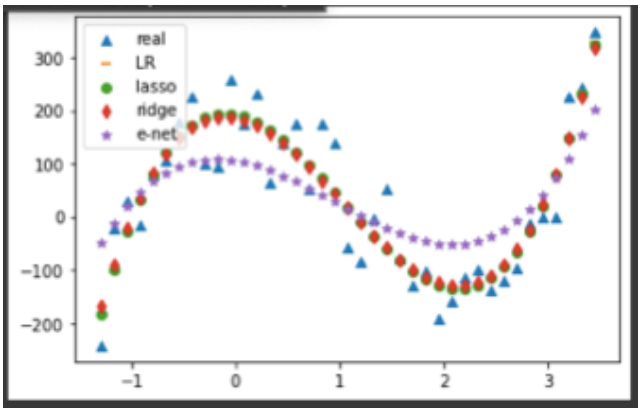

Figura 4. Técnicas de regularización, alfa = 1.

Gracias al análisis y ajuste de las variables podemos observar que al aumentar el valor de alfa, los coeficientes de los modelos de regularización se limitan, es decir que el modelo los castiga y hace que estos no crecen descontroladamente, lo cual es algo bueno ya que se evita el sobreajuste (overfitting). Desafortunadamente cuando esto pasa, nuestra curva del modelo tiende a hacerse más plana, por lo que se despega mucho de nuestro valores reales y no obtendremos buenas predicciones. (Ejemplo figura 2).

Por otro lado, cuando bajamos el valor de alfa, nuestra curva se asemeja más a los valores reales y las predicciones serán más acertadas, sin embargo, tenemos que tener cuidado de no caer en el overfitting, es decir, evitar que nuestro modelo pase justo por encima de los valores reales, pues esto significa que el modelo en lugar de estar prediciendo, simplemente está solo memorizando las posiciones de los datos y cuando nuevos datos aparezcan, el modelo no será capaz de hacer una predicción acertada.

Por último, los valores de l1 ratio no considero que tengan un papel muy relevante, pues la diferencia entre los pesos del modelo RIDGE no cambian significativamente.

Concluyendo esta parte, los modelos que serían más óptimos para utilizar serían el de LASSO y RIDGE si deseamos evitar a toda cosa el overfitting, o simplemente seguir con el método de Regresión Lineal sin regularización. Creo que lo mejor sería quedarnos con un rango de valores de alfa de entre 5 y 15. En mi opinión, un valor de 30, como estaba definido el código, es un buen valor, sin embargo creo que todavía podría comportarse mejor si lo bajamos un poco.

4.- ¿Están subentrenados?

Un modelo subentrenado es aquel que al ser demasiado simple, no resulta suficientemente flexible para ajustarse a los datos reales (sesgo), por lo cual su pronóstico sería pobre. Tienen muy pocos grados de libertad, es decir muy poca varianza.
Un ejemplo de esto puede ser cuando el alfa lo ajustamos a 1000, como lo vemos en la figura 2. Las curvas de LASSO y RIDGE son casi planas, como si supusiéramos que los valores de salida y tienen una relación constante respecto a cada entrada x.

5.- ¿Están sobreentrenados?

Por otro lado, los modelos sobreentrenados (overfitting) son aquellos que tienen muchos grados de libertad, es decir, que es un polinomio de grado alto. Lo que sucede con estos modelos es que al ser demasiado flexibles, pasan justo por encima de los datos de entrenamiento, lo que nos dice que el modelo más que estar prediciendo, está memorizando esos datos, por lo que cuando utilicemos ese modelo para los datos de prueba y para casos nuevos, no nos dará predicciones buenas y estará considerando como válidos solo los datos aquellos que sean idénticos al conjunto de datos de entrenamiento. Estos modelos además recopilan muchos ruidos de los datos de entrenamiento y tienen mucha varianza.

Considero que para este conjunto de datos específicamente, sería muy difícil que el modelo tienda a estar sobreentrenado, pues aun cuando ponemos una alfa = 0.001, el modelo todavía no iguala la trayectoria de los datos. Además, recordando que el promedio sigue siendo entre

un 0.86 y 0.87 para todos los modelos, considero que no es un porcentaje tan alto como para suponer que el modelo este memorizando los datos de entrenamiento.

6.- ¿Qué otra información necesitarías para responder estas preguntas?

Creo que el siguiente paso que nos ayudaria a identificar y concluir de manera segura que un modelo está subentrenado o sobreentrenado, y que tal modelo es mejor que otro para determinada aplicación, es tomar el conjunto de datos de prueba u otros datos nuevos para observar cómo se comporta el modelo.

Referencias:

1. *Regularización*. (2022, 7 septiembre). BigData Javier Heras. Recuperado 1 de octubre de 2022, de https://blog.javierheras.website/regularizacion-de-machine-learning/

2. undefined [Luis R. Izquierdo]. (2020, 15 marzo). *1. Sobreajuste (overfitting) y subajuste (underfitting) en Machine Learning (1/2)* [Vídeo]. YouTube. Recuperado 2 de octubre de 2022, de https://www.youtube.com/watch?v=NLp2yhoR_HE&list=PLZT_mz9CSgHvz0wy06e6GDAyAAv8FvWnu&index=5
3. Falcón, L. (2022, septiembre). *Lectura. Teoría: Aprendizaje supervisado y no-supervisado; Regresión logística y Tipo de errores*. Canvas Experiencia 21. Recuperado 30 de septiembre de 2022, de https://experiencia21.tec.mx/courses/320441/pages/lectura-teoria-aprendizaje-supervisado-y-no-supervisado-regresion-logistica-y-tipo-de-errores?module_item_id=19377500
4. Pramoditha, R. (2022, 5 enero). *The Choice of Regularization: Ridge, Lasso and Elastic Net Regression*. Medium. Recuperado 30 de septiembre de 2022, de https://towardsdatascience.com/the-choice-of-regularization-ridge-lasso-and-elastic-net-regression-fc696f697209